

OMOP on Yhdysvalloista lähtöisin olevat malli, jolla pyritään yhdenmukaistamaan eri lähteistä tulevat sähköiset potilasaineistot ja terveysaineistot. Esimerkiksi samalle toimenpiteelle, diagnosoille tai oireelle voi olla erilaisia nimityksiä, mutta tuossa mallissa ne on kaikki tarkoitus saada saman käsitteen ja koodin alle. Näin ollen saadaan suuri yhdenmukainen tietokanta, jota voidaan käyttää esimerkiksi lääketieteellisessä tutkimuksessa.

FinOMOP on OMOPin suomalainen versio, jossa käytetään suomalaista eri lähteistä tulevaa dataa ja saatetaan se yhdenmukaiseksi. Ymmärtääkseni ainakin osa käsitteistä muunnetaan varsinaisen OMOP-mallin mukaisiksi, mutta osa käsitteistä on vain suomalaisten omaa dataa, jolla ei ole vastinetta kansainvälisessä datassa. Tavoitteena on ilmeisesti, että jossain vaiheessa suomalaista ja kansainvälistä dataa voidaan yhdistää tutkimuksia tehtäessä.

Ylläolevan perusteella hahmottelin kolme tehtävää T1, T2 ja T3, joiden kuvittelisin jollain tavalla liittyvän työtehtävään.

T1 tehtävässä kootaan viidestä eri lähteestä tuleva data yhdeksi yhdenmukaiseksi tietokantatauluksi.

T2 tehtävässä käytetään T1 tehtävässä muodostunutta dataa ja louhitaan sen vapaa teksti-kentästä tiettyyn aihepiiriin kuuluva sana.

T3 tehtävässä on otettu Mira Kilven opinnäytetyöstä

(https://www.finna.fi/Record/theseus_metropolia.10024_801038) esimerkki manuaalisesta kansallisen koodiston sovittamisesta kansainväliseen standardiin ja tehty siitä tietoteknisempi versio.

T1 tehtävän ensimmäisessä vaiheessa kehitin ensin satunnaista terveystietodataa luovat ohjelmat sekä R-kielillä että Python-kielillä. Python-ohjelma tuotti json-, excel-, csv- ja parquet-tiedostot ja R-ohjelma tuotti RDS-tiedoston. Loin vakiodatan, jota käytetään satunnaistuksessa, tekoälyn avulla tehden siihen itse pieniä muutoksia, jotta se oli sujuvampi. Ohjelmien rakenteen tein itse ja samaten kuin satunnaistamiskoodin. "Vapaa teksti"-kenttien kehittämisessä pyysin tekoälyä esittelemään erilaisia malleja, joilla sen voisi toteuttaa ja sitten valitsin ja muokkasin niistä mielestäni sopivimman. Koska olen käyttänyt R-kieltä aikaisemmin vain laskentaan tein R-koodin käytännössä vain vaihtamalla Python koodin syntaksin R-koodin syntaksiin.

Jotta tehtävässä olisi jotain järkeä tein tiedostoihin erilaisia sarakkeita eri järjestyksessä ja satunnaistamisen avulla istutin virheitä joihinkin kenttiin.

T1 tehtävän toisessa vaiheessa konvertoin kaikki datatiedostot csv-muotoon ja siirsin ne tietokantaan tauluiksi, jossa käsitelin niitä medallion-arkkitehtuurin ideaa hyödyntäen. SQL-kommentoin yhdenmukaistin tietokantataulut ja validoin ne samalla poistaen satunnaisesti istutetut virheet. Lopulta yhdistin ne yhdeksi tauluksi, jota käytän tehtävässä T2. SQL-koodia kopioin omista vanhemmista projekteistani ja käytin tekoälyä SQL-koodin syntaksien muisteluun sekä erilaisten ratkaisuvaihtoehtojen esittelyyn. T1 koodit ovat hakemistoissa R, SQL ja python.

T2 tehtävässä louhin tekstiä T1 tehtävän lopputuloksena valmistuneesta tietokantataulusta. Tein louhintaa varten ohjelmat SQL-, R- ja Python-kielillä. Olin asettanut datan vapaan tekstin kenttiin 20% rokotuksia sisältäviä kirjauksia. Laskin eri ohjelmilla rokotus mainintojen määrät ja rokotus rivien määrät ja lopuksi vertasin, että ne ovat samat. Käytin tekoälyä kertomaan erilaisista louhintatavoista ja valitsin niistä mielestäni tehtävään sopivimman ja muokkasin siitä ohjelman. T2 koodit ovat hakemistossa T2.

T3 tehtävässä otin Miran Kilven opinnäytetyöstä koodiston sovittamisen esimerkkitapauksen ja tein sen valmistelusta Usagia varten SQL-version. Päivämäärät olivat minulla oikeassa muodossa, mutta halusin muuntaa niitä, joten muutin ne DD.MM.YYYY muotoon. Tehtävä oli suoraviivainen ja käytin tekoälyä vain SQL-syntaksin muisteluun. T3 koodit ovat hakemistossa T3.